



TITANIC: MACHINE LEARNING FROM DISASTER

Lê Thị Thuỷ Tiên
Trương Thị Huyền Trang
Nguyễn Dương Bảo Trân
Giang Hào Tường


<https://www.kaggle.com/competitions/titanic/overview>

Tổng quan nội dung

1. INTRODUCTION
2. RELATED WORK
3. PROPOSE METHODS
4. EXPERIENCE AND RESULTS
5. CONCLUSION


INTRODUCTION

TÌNH HUỐNG:



Tảng băng trôi

Tàu Titanic va phải tảng băng trôi
khi đang trong chuyến hải trình
đầu tiên.



Tai nạn chìm tàu Titanic vào
năm 1912

Thảm họa hàng hải
lớn nhất lịch sử


VẤN ĐỀ:

Input:

Các đặc điểm, thông tin cá nhân
của hành khách trên tàu

Output:

dự đoán tỷ lệ sống của
hành khách: (1: Sống, 0: Chết)



Mô hình

Sống: 38.38 %

Chết: 61.62 %

INTRODUCTION

Titanic - Machine Learning from Disaster

Start here! Predict survival on the Titanic and get familiar with ML basics

[k](#) [kaggle.com](#)

Dataset: lấy từ Kaggle (891 mẫu và 418 bản kiểm thử)

PassengerId	Mã hành khách
Survived	Kết quả sống hoặc chết (1 hoặc 0)
Pclass	Hạng vé
Name	Tên hành khách
Sex	Giới tính
Age	Độ tuổi

SibSp	Số lượng anh chị em hoặc vợ/chồng
Parch	Số lượng cha mẹ hoặc con cái
Ticket	Mã vé
Fare	Giá vé
Cabin	Số phòng
Embarked	Cảng

INTRODUCTION

Thách thức:



Missing values (%):
Cabin 77.104377
Age 19.865320
Embarked 0.224467

train.csv

Missing values (%):
Cabin 78.229665
Age 20.574163
Fare 0.239234

test.csv


Phân bố biến mục tiêu (Survived)




Nhiều giá trị bị thiếu (Age, Embarked Fare ...)
=> Làm cho dữ liệu mất cân bằng và tỉ lệ sống sót ít.

RELATED WORK


Các mô hình được sử dụng để xử lý dữ liệu Titanic:




LogisticRegression




DecisionTree




RandomForest



GradientBoosting



SVM



XGBoost

Các mô hình này đã được chứng minh hiệu quả trên Kaggle: Titanic - Machine Learning from Disaster

RELATED WORK

Kỹ thuật tạo đặc trưng mới:

= SibSp + Parch + 1 (tính cho chính hành khách).

= Fare / FamilySize

Phân loại độ tuổi thành các nhóm

= FamilySize * FarePerPerson

	FamilySize	IsAlone	FarePerPerson	Title	Deck	AgeBin	FareBin	FamilyFare	Title_Sex
0	2	0	3.62500	Mr	U	2	Low	7.2500	Mr_male
1	2	0	35.64165	Mrs	C	2	VeryHigh	71.2833	Mrs_female
2	1	1	7.92500	Miss	U	2	Mid	7.9250	Miss_female
3	2	0	26.55000	Mrs	C	2	VeryHigh	53.1000	Mrs_female
4	1	1	8.05000	Mr	U	2	Mid	8.0500	Mr_male

If FamilySize = 1
→ IsAlone = 1.
Else IsAlone = 0

Có Cabin = "C"
Không Cabin = "U"
(Unknow)


Chia các giá vé thành 4 nhóm theo phân vị

Kết hợp Title & Sex → Tính năng mới

- Điền giá trị khuyết bằng trung vị, mode hoặc dự đoán từ mô hình hỗ trợ.

PROPOSE METHODS



Quá trình thực hiện:



PROPOSE METHODS


Exploratory data analysis (EDA):

Giới tính là yếu tố then chốt trong việc dự đoán sự sống sót → khi **nữ giới** được **ưu tiên** cứu hộ nên có **xác suất sống cao** hơn nam giới.



Hành khách lên tàu tại C có tỷ lệ **sống sót cao hơn** so với các cảng S và Q,
→ Địa điểm lên tàu có thể liên quan đến điều kiện kinh tế, vị trí khoang
→ Ảnh hưởng đến cơ hội sống sót.



Hành khách ở **hạng vé cao hơn (Pclass 1)** có **xác suất sống sót cao** hơn đáng kể so với **hạng thấp (Pclass 3)**,
→ Phản ánh ưu tiên cứu hộ cho những người ở khoang hạng nhất.



PROPOSE METHODS

Exploratory data analysis (EDA):

Đi cùng gia đình giúp **tăng khả năng sống sót**, trong khi những người đi một mình có tỷ lệ **sống sót thấp** hơn.



PROPOSE METHODS

Tiền xử lý dữ liệu (Preprocessing):

Xử lý các giá trị thiếu:


Age	median()
Embarked	mode()
Fare	median()

Cabin: Thay giá trị thiếu bằng 'Unknown'

Age, Fare: Cột số -> chuẩn hóa(Scaler)

Sex, Embarked, Pclass, SibSp, Parch: Cột chuỗi
-> mã hóa (Encoder)

Tạo đặc trưng mới:




	FamilySize	IsAlone	FarePerPerson	Title	Deck	AgeBin	FareBin	FamilyFare	Title_Sex
0	2	0	3.62500	Mr	U	2	Low	7.2500	Mr_male
1	2	0	35.64165	Mrs	C	2	VeryHigh	71.2833	Mrs_female
2	1	1	7.92500	Miss	U	2	Mid	7.9250	Miss_female
3	2	0	26.55000	Mrs	C	2	VeryHigh	53.1000	Mrs_female
4	1	1	8.05000	Mr	U	2	Mid	8.0500	Mr_male

PROPOSE METHODS

Chuẩn hóa (normalization):

- Áp dụng **StandardScaler** cho các đặc trưng số (Age, Fare, FamilySize, ...).
- Áp dụng **OneHotEncoder** cho các đặc trưng phân loại (Sex, Embarked, Pclass, ...).




PROPOSE METHODS

Đánh giá huấn luyện:

Đánh giá bằng Cross-Validation:

- **Mục đích:** Đảm bảo mô hình được đánh giá ổn định và công bằng, với tỉ lệ sống sót (~38%) được giữ cân bằng trong mỗi lần chia dữ liệu.
- **Thực hiện:** Sử dụng Stratified K-Fold (k=10) để đánh giá mô hình qua 10 lần huấn luyện – kiểm tra, rồi lấy trung bình các chỉ số (Accuracy, F1, ROC-AUC) phản ánh hiệu suất tổng thể.




PROPOSE METHODS

Đánh giá huấn luyện:

Đánh giá bằng `train_split_test`::

- **Mục đích:** Kiểm tra hiệu suất mô hình trên tập kiểm tra riêng (20%) để đánh giá khả năng tổng quát ban đầu.
- **Phân chia:** Dữ liệu được tách 80% huấn luyện (`x_train, y_train`)– 20% kiểm tra (`x_val, y_val`).
- **Ứng dụng:** Dùng để so sánh giữa các mô hình và xác định ứng viên tốt trước khi chạy đánh giá bằng Cross-Validation.



EXPERIENCE AND RESULTS

Train/Test Split Evaluation

Model	Accuracy	F1 Score	ROC AUC
Logistic Regression	0.8268	0.7891	0.8934
DecisionTree	0.7877	0.7500	0.7917
RandomForest	0.8268	0.7919	0.9043
XGBoost	0.8156	0.7692	0.8839
SVM	0.8156	0.7692	0.8551
GradientBoosting	0.8268	0.7862	0.9029

K-Fold Cross Validation

Model	Accuracy	F1 Score	ROC AUC
Logistic Regression	0.8036	0.7397	0.8592
DecisionTree	0.7856	0.7184	0.7732
RandomForest	0.8148	0.7572	0.8740
XGBoost	0.8283	0.7701	0.8751
SVM	0.8305	0.7705	0.8656
GradientBoosting	0.8361	0.7773	0.8762

=> 3 MÔ HÌNH TỐT NHẤT: LOGISTIC REGRESSION, SVM, GRADIENTBOOSTING

CONCLUSION

Mô hình Voting (soft) kết hợp

GradientBoosting, SVM và Logistic Regression giúp tận dụng ưu điểm khác nhau của từng mô hình: khả năng học phi tuyến mạnh của GradientBoosting, biên phân tách tốt của SVM và tính tuyến tính ổn định của Logistic

✓	submission.csv Complete · 1d ago · svm	0.77990
✓	submission.csv Complete · 1d ago · gradient boosting	0.77033
✓	submission.csv Complete · 1d ago · logistic	0.77511
✓	submission.csv Complete · 1d ago · voting classifier	0.78468

Nhờ đó, mô hình cho kết quả chính xác và ổn định hơn so với từng mô hình đơn lẻ, chứng minh hiệu quả của phương pháp ensemble trên bài toán Titanic.

2111

Bào Trần Nguyễn Dương



0.78468

20

4h



Your Best Entry!

Your most recent submission scored 0.77990, which is not an improvement of your previous score. Keep trying!



**THANKS FOR
WATCHING**