



Challenge 1: Ứng dụng học máy để dự đoán sống sót sau thảm họa Titanic

Nguyễn Dương Bảo Trân – Lê Thị Thủy Tiên – Trương Thị Huyền Trang – Giang Hào Tường

Giới Thiệu

Input:

Dữ liệu được thu thập từ các đặc trưng và thông tin của hành khách trên tàu Titanic (Pclass, Sex, Age, sibsp, parch, ticket, fare, cabin, embarked).

Output:

Dùng mô hình học máy để dự đoán sự sống còn của hành khách tàu Titanic (0: chết, 1: sống).

Thử thách:

Tập dữ liệu mất cân bằng, chứa rất nhiều giá trị thiếu như Cabin, Age, Fare. Mỗi quan hệ phức tạp, phi tuyến tính giữa các đặc điểm và khả năng sống sót.

Mục tiêu:

Phân tích dữ liệu hành khách trên tàu Titanic và phát triển mô hình học máy dự đoán phân loại kết quả sống sót với độ chính xác cao.

Bộ dữ liệu

Nguồn dữ liệu: Titanic Dataset – Kaggle Version.

<https://www.kaggle.com/c/titanic/data>


PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	Unknown	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Catie"	female	28.0	1	2	W./C. 6607	23.45	Unknown	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	Unknown	Q

891 dữ liệu (train.csv)


PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	IsAlone	Title	Deck	FarePerPerson	
413	1305	3	Specter, Mr. Woolf	male	27.0	0	0	A. 3236	8.0500	Unknown	S	1	1	Mr	U	8.050000
414	1306	1	Oliva y Orona, Dona. Femila	female	39.0	0	0	PC 17738	108.9000	C105	C	1	1	Baron	C	108.900000
415	1307	3	Saethel, Mr. Simon Sivertsen	male	35.5	0	0	SCOTON/O.Q. 3101362	7.2500	Unknown	S	1	1	Mr	U	7.250000
416	1308	3	Ward, Mr. Frederick	male	27.0	0	0	359399	8.0500	Unknown	S	1	1	Mr	U	8.050000
417	1309	3	Peter, Master. Michael J	male	27.0	1	1	2688	22.3583	Unknown	C	3	0	Master	U	7.452757

418 dữ liệu (test.csv)


PassengerId	Mã hành khách	SibSp	Số lượng anh chị em hoặc vợ/chồng
Survived	Kết quả sống hoặc chết (1 hoặc 0)	Parch	Số lượng cha mẹ hoặc con cái
Pclass	Hạng vé	Ticket	Mã vé
Name	Tên hành khách	Fare	Giá vé
Sex	Giới tính	Cabin	Số phòng
Age	Độ tuổi	Embarked	Cảng



Phương pháp đề xuất



Phân tích khám phá dữ liệu



Missing values (%):
Cabin 77.104377
Age 19.865320
Embarked 0.224467

train.csv

Missing values (%):
Cabin 78.229665
Age 20.574163
Fare 0.239234

test.csv

Tiền xử lý dữ liệu

Xử lý dữ liệu thiếu:

Age	median()
Embarked	mode()
Fare	median()

- Cabin: Thay giá trị thiếu bằng 'Unknown'
- Age, Fare: Cột số -> chuẩn hóa (Scaler)
- Sex, Embarked, Pclass, SibSp, Parch: Cột chuỗi -> mã hóa (Encoder)

Tạo đặc trưng mới:



FamilySize	Quy mô gia đình -> tăng khả năng sống sót
IsAlone	Đi một 1 mình hoặc cùng người thân
FarePerPerson	Giá vé bình quân
Title	Danh xưng
Deck	Khu vực phòng (Tầng)
AgeBin	Phân loại nhóm tuổi
FareBin	Loại vé
FamilyFare	Tổng chi phí vé của gia đình
Title_Sex	Kết hợp danh xưng và giới tính

Huấn luyện mô hình



Đánh giá mô hình



Thí nghiệm

Train/Test Split Evaluation

Model	Accuracy	F1 Score	ROC AUC	Model	Accuracy	F1 Score	ROC AUC
Logistic Regression	0.8268	0.7891	0.8934	Logistic Regression	0.8036	0.7397	0.8592
DecisionTree	0.7877	0.7500	0.7917	DecisionTree	0.7856	0.7184	0.7732
RandomForest	0.8268	0.7919	0.9043	RandomForest	0.8148	0.7572	0.8740
XGBoost	0.8156	0.7692	0.8839	XGBoost	0.8283	0.7701	0.8751
SVM	0.8156	0.7692	0.8551	SVM	0.8305	0.7705	0.8656
GradientBoosting	0.8268	0.7862	0.9029	GradientBoosting	0.8361	0.7773	0.8762

=> 3 mô hình tốt nhất: Logistic Regression, SVM, GradientBoosting

Mô hình Voting (soft) kết hợp GradientBoosting, SVM và Logistic Regression giúp tận dụng ưu điểm khác nhau của từng mô hình: khả năng học phi tuyến mạnh của GradientBoosting, biên phân tách tốt của SVM và tính tuyến tính ổn định của Logistic.

Kết quả



Thành tích trên
Kaggle: 0.78468