



Challenge 1: Ứng dụng học máy để dự đoán sống sót sau thảm họa Titanic

Nguyễn Dương Bảo Trân – Lê Thị Thủy Tiên – Trương Thị Huyền Trang – Giang Hào Tường

Giới Thiệu

Input:

Dữ liệu được thu thập từ các đặc trưng và thông tin của hành khách trên tàu Titanic (Pclass, Sex, Age, sibsp, parch, ticket, fare, cabin, embarked).

Output:

Dùng mô hình học máy để dự đoán sự sống còn của hành khách tàu Titanic (0: chết, 1: sống).

Thử thách:

Tập dữ liệu mất cân bằng, chứa rất nhiều giá trị thiếu như Cabin, Age, Fare. Mỗi quan hệ phức tạp, phi tuyến tính giữa các đặc điểm và khả năng sống sót.

Mục tiêu:

Phân tích dữ liệu hành khách trên tàu Titanic và phát triển mô hình học máy dự đoán phân loại kết quả sống sót với độ chính xác cao.

Bộ dữ liệu

Nguồn dữ liệu: Titanic Dataset – Kaggle Version.

<https://www.kaggle.com/c/titanic/data>


PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	Unknown	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carnie"	female	28.0	1	2	W./C. 6607	23.45	Unknown	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	Unknown	Q

891 dữ liệu (train.csv)


PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	FamilySize	isMale	Title	Fare/FamilySize
413	1305	3 Spector, Mr. Woolf	male	27.0	0	0	A. 3236	8.0500	Unknown	S	1	1	Mr	8.05000
414	1306	1 Oliva y Ocas, Dona. Femila	female	39.0	0	0	PC 17758	108.9000	C105	C	1	1	Rate	C 108.90000
415	1307	3 Saether, Mr. Simon Sivertsen	male	35.5	0	0	5070N/O.G. 3101362	7.2500	Unknown	S	1	1	Mr	7.25000
416	1308	3 Ware, Mr. Frederick	male	27.0	0	0	359399	8.0500	Unknown	S	1	1	Mr	8.05000
417	1309	3 Peter, Master. Michael J	male	27.0	1	1	2688	22.3583	Unknown	C	3	0	Master	7.45267

418 dữ liệu (test.csv)

PassengerId	Mã hành khách	SibSp	Số lượng anh chị em hoặc vợ/chồng
Survived	Kết quả sống hoặc chết (1 hoặc 0)	Parch	Số lượng cha mẹ hoặc con cái
Pclass	Hạng vé	Ticket	Mã vé
Name	Tên hành khách	Fare	Giá vé
Sex	Giới tính	Cabin	Số phòng
Age	Độ tuổi	Embarked	Cảng




Phương pháp đề xuất



Phân tích khám phá dữ liệu

Thực quan hóa theo biến mục tiêu (Survived):



Missing values (%):
Cabin 77.104377
Age 19.865320
Embarked 0.224467

train.csv

Missing values (%):
Cabin 78.229665
Age 20.574163
Fare 0.239234


test.csv

Phát hiện giá trị ngoại lai (Outlier):

Boxplot của Fare



Fare có nhiều giá trị ngoại lai (outlier) nằm ở phía giá vé cao, trong khi phần lớn hành khách có vé dưới 100



Age phân bố khá đều, ít outlier, đa phần nằm trong khoảng [20-40 tuổi]

Tiền xử lý dữ liệu

Xử lý dữ liệu thiếu:

Age	median()
Embarked	mode()
Fare	median() của từng nhóm Pclass

*Chuẩn hóa dữ liệu:

- Age, Fare: chuẩn hóa bằng MinMaxScaler



- Age: phân bố tập trung quanh trung vị, có vài giá trị ngoại lệ (tuổi cao).
- Fare: lệch phải, nhiều giá trị thấp và vài vé giá rất cao.


Tạo đặc trưng mới:

Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked	HasCabin	Deck	Title	FamilySize	IsAlone	AgeBin	FareBin	Survived
0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
1	0	2	1	2	1	2	0	0	0	0	0	0	0	0	0	0
2	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
3	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
4	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
5	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
6	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
7	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
8	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
9	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

- Cabin: Thay giá trị thiếu bằng 'Unknown'
- Sex, Embarked, Pclass, SibSp, Parch: Cột chuỗi -> mã hóa (LabelEncoder)

HasCabin	Có cabin -> tầng lớp cao -> tỷ lệ sống sót cao
Deck	Khu vực tầng B, C, D -> gần thuyền cứu sinh -> tỷ lệ sống sót cao
Title	Danh xưng là nữ -> ưu tiên sống sót
FamilySize	Quy mô gia đình
IsAlone	Đi 1 mình -> tỷ lệ sống sót rất thấp
AgeBin	Phân loại nhóm tuổi -> ưu tiên cứu trẻ em
FareBin	Nhóm giá vé -> giá vé cao -> tỷ lệ sống sót cao -> phản ánh quan hệ với Pclass

Huấn luyện mô hình



Thí nghiệm

Mô hình trước khi trích xuất đặc trưng

Model	Accuracy	Precision	Recall	F1
1 Gradient Boosting	0.837050	0.824784	0.709075	0.761776
5 Logistic Regression	0.797550	0.746311	0.693096	0.714517
2 Random Forest	0.794933	0.742044	0.693583	0.714095
4 XGBoost	0.787891	0.735838	0.680712	0.702736
3 Decision Tree	0.779441	0.711446	0.685534	0.695452
0 SVM	0.682727	0.662451	0.310426	0.417568

Mô hình Gradient Boosting đạt hiệu năng cao nhất

Mô hình sau khi trích xuất đặc trưng

Model	Accuracy	Precision	Recall	F1
3 Gradient Boosting	0.824452	0.788679	0.709963	0.746410
0 Logistic Regression	0.807590	0.764969	0.695254	0.724622
5 SVM	0.794992	0.733019	0.706629	0.717304
2 Random Forest	0.796303	0.747804	0.687202	0.713555
4 XGBoost	0.789300	0.733354	0.693438	0.708794
1 Decision Tree	0.757023	0.673598	0.666265	0.668539

Sử dụng Voting kết hợp nhiều mô hình để cải thiện F1 thêm +0.07
=> giảm dự đoán sai ở cả 2 lớp

Độ chính xác (Voting Classifier): 0.8268				
Bảo cáo phân loại:				
	precision	recall	f1-score	support
0	0.85	0.86	0.85	105
1	0.79	0.78	0.79	74
accuracy			0.83	179
macro avg	0.82	0.82	0.82	179
weighted avg	0.83	0.83	0.83	179

Tiến hành tinh chỉnh siêu tham số cho các mô hình thành phần trong Voting Classifier nhằm tối ưu hóa hiệu năng tổng thể.

GridSearchCV với chiến lược cross-validation k=5

3 mô hình được tinh chỉnh với trọng số:

Gradient Boosting: 0.4 Random Forest: 0.3
Logistic Regression: 0.3

Final Validation Accuracy (Voting): 0.8492				
Classification Report:				
	precision	recall	f1-score	support
0	0.86	0.89	0.87	105
1	0.83	0.80	0.81	74
accuracy			0.85	179
macro avg	0.85	0.84	0.84	179
weighted avg	0.85	0.85	0.85	179


Mô hình chạy tổ hợp và tìm ra bộ tham số tốt nhất

Kết quả


submission.csv
Complete - now

0.77033

Đánh giá mô hình




Gradient Boosting vẫn giữ được khả năng tổng quát hóa tốt sau khi tinh chỉnh đặc trưng. So sánh Accuracy Trước và Sau Feature Engineering



Accuracy: 0.8268 Precision: 0.7808 Recall: 0.7891 F1-score: 0.7891				
Classification Report:				
	precision	recall	f1-score	support
0	0.85	0.86	0.85	105
1	0.79	0.78	0.79	74
accuracy			0.83	179
macro avg	0.82	0.82	0.82	179
weighted avg	0.83	0.83	0.83	179

Đã huấn luyện và lưu mô hình Voting Classifier tại: VotingClassifier_best.pkl

Mã trận nhầm lẫn



Voting Classifier cho kết quả dự đoán khá tốt, khi nhận diện chính xác 93/105 hành khách không sống sót và 59/74 hành khách sống sót.

Thành tích trên Kaggle: 0.77033